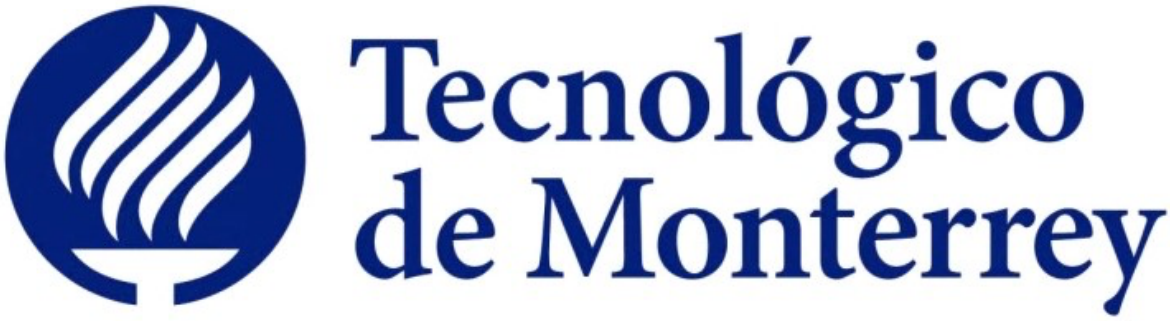


Campus Monterrey

Propuesta de proyecto

Inteligencia artificial avanzada para la ciencia de datos

Grupo 602

Miranda Urban Solano A01752391

Lunes 12 de octubre de 2026

Propuesta de proyecto: Predicción del rendimiento de corredores recreativos con Deep Learning

Problema y pregunta

Para el desarrollo de este trabajo, el objetivo es predecir la velocidad de carrera de corredores recreativos a partir de sus características y hábitos de entrenamiento. Concretamente, la pregunta que guía el proyecto es:

> ¿Cuánto aportan las variables de entrenamiento (kilometraje semanal, intervalos, tempo runs) sobre las demográficas (edad, sexo, BMI) para predecir la velocidad en carrera con base en una red MLP que captura dichas interacciones no lineales?

El planteamiento de este problema es relevante porque permite entender qué factores accesibles para cualquier corredor, sin necesidad de pruebas de laboratorio, se asocian con el rendimiento. Por lo tanto, se presenta como una herramienta de gran utilidad práctica para optimizar el entrenamiento y evaluar el desempeño de forma masiva.

Datos

A continuación se descibe a detalle la fuente de los datos que se utilizarán para el desarrollo de la solución:

- Fuente: Vickers & Vertosick (2016), *An empirical study of race times in recreational endurance runners*, BMC Sports Science, Medicine and Rehabilitation, 8:26.
- Acceso: https://pmc.ncbi.nlm.nih.gov/articles/PMC5000509/ *(Additional file 2, `.xlsx`).*
- Licencia: artículo bajo CC BY 4.0; los datos incluidos en el artículo y sus archivos adicionales se publican bajo la renuncia CC0, salvo indicación contraria.
- Origen: encuesta en línea (abril-junio de 2014) a corredores recreativos; datos autorreportados.
- Estructura: una fila por corredor (`id`), con columnas para cada distancia de carrera (`k5_*`, `k10_*`, `m5_*`, `m10_*`, `mh_*`, `mf_*`). Cada grupo tiene sufijos:
  - `_d`: distancia reportada
  - `_ti`: tiempo reportado
  - `_ti_adj`: tiempo ajustado
  - `_tr`: indicador de si terminó
  - `_di`: indicador de lesión/dificultad
- Variable objetivo: velocidad de carrera (derivada de distancia y tiempo).

Alcance del notebook de esta entrega

El notebook para la primera entrega tiene dos objetivos:

1. Demostrar contacto con los datos: carga correcta, número de ejemplos, estructura de las entradas, distribución del objetivo y riesgos observados.
2. Sustentar la propuesta con una prueba preliminar: entrenar de forma básica los modelos que propongo para verificar que el planteamiento es viable.

Baseline

Para tener un punto de comparación antes de aplicar cualquier modelo de Deep Learning, se definen dos baselines simples:

- Media de velocidad por sexo: predicción ingenua que asigna a cada carrera la media de velocidad observada en el conjunto de entrenamiento para ese sexo.
- Ridge (regresión lineal regularizada): modelo tradicional que usa todas las features con regularización L2. Sirve para medir cuánto de la señal es capturable con una relación lineal.

Ambos se evalúan con la misma partición por corredor, el mismo preprocesamiento y las mismas métricas (MAE y RMSE) que se usarán con la MLP, de modo que las comparaciones sean justas.

Familia de modelos

Se propone una MLP (multilayer perceptron) porque las entradas son tabulares: una mezcla de variables numéricas (edad, BMI, kilometraje semanal, número de intervalos, etc.) y categóricas codificadas (sexo, grupo de edad, etc.). La MLP permite capturar interacciones no lineales entre volumen de entrenamiento, intensidad y demografía que una regresión Ridge no modela.

Como referencia adicional para la entrega final se contempla gradient boosting, que suele ser fuerte en datos tabulares y ayuda a distinguir si la ganancia proviene de la no linealidad o específicamente de una red neuronal.

Primer experimento

- Hipótesis: una MLP pequeña captura interacciones no lineales entre variables de entrenamiento (kilometraje, intervalos, tempo runs) y demográficas (edad, sexo, BMI) que Ridge no logra, reduciendo el RMSE en validación.
- Variable que se modifica: familia de modelo (Ridge lineal vs. MLP con 2 capas ocultas, ReLU, dropout y weight decay).
- Condiciones que se mantienen: mismas features, misma partición por corredor, mismo preprocesamiento, sin ajuste de hiperparámetros.
- Métrica principal: RMSE en validación (MAE como secundaria).
- Resultados que apoyarían la hipótesis: RMSE de la MLP menor que el de Ridge.
- Resultados que debilitarían la hipótesis: RMSE de la MLP igual o peor que Ridge, lo que sugeriría que el problema es esencialmente lineal con estas features.

Este experimento es preliminar: no responde la pregunta de investigación, solo verifica que el pipeline es viable y da un orden de magnitud del error. El experimento controlado completo

(ablation de grupos de variables, validación cruzada por corredor y varias semillas) se desarrollará en la entrega final.

Viabilidad

- Recursos: el dataset es pequeño (aprox. 2 000 carreras, ~1 000 corredores), por lo que el entrenamiento puede realizarse en poco tiempo y sin infraestructura compleja.
- Tiempo estimado: 2–3 semanas para la ablation completa con validación cruzada por corredor y varias semillas.
- Principal riesgo: fuga de información por corredor si las particiones no se agrupan correctamente. Mitigación: filtrar por ID de corredor desde el inicio y verificar que ninguna carrera de un corredor aparezca en train y validación a la vez. Este riesgo está respaldado por la literatura sobre validación cruzada en datos estructurados: cuando existen dependencias (temporales, espaciales, jerárquicas o por grupo), la CV aleatoria subestima el error predictivo y puede favorecer el overfitting con predictores no causales, incluso en modelos que controlan correlaciones. Por ello se propone la adopción de ***block CV*** agrupada por corredor, más adecuada dado que el objetivo es predecir a nuevos datos o seleccionar predictores causales. Evidencia comparativa en 72 datasets tabulares (576 experimentos) respalda además que, en entornos complejos y ruidosos, los modelos no lineales como XGBoost o MLP rinden mejor que alternativas lineales, mientras que los lineales son más robustos en escenarios simples —de ahí que se mantenga Ridge como baseline y se contraste con la MLP.
- Alternativa de menor alcance: si la ablation no muestra una ganancia clara de la MLP sobre Ridge, el proyecto se reorienta a un diagnóstico de qué variables aportan y bajo qué condiciones, sin cambiar de familia de modelo.

Referencias

Roberts, D. R., Bahn, V., Ciuti, S., Boyce, M. S., Elith, J., Guillera-Arroita, G., Hauenstein, S., Lahoz-Monfort, J. J., Schroeder, B., Thuiller, W., Warton, D. I., Wintle, B. A., Hartig, F., & Dormann, C. F. (2017). Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure. *Ecography*, *40*(8), 913–929. https://doi.org/10.1111/ecog.02881

Stumpfe, S. F., & Shongwe, S. C. (2026). Comparative Analysis and Optimisation of Machine Learning Models for Regression and Classification on Structured Tabular Datasets. Mathematics, 14(3), 473. https://doi.org/10.3390/math14030473

Vickers, A., & Vertosick, E. (2016). An empirical study of race times in recreational endurance runners. BMC sports science, medicine & rehabilitation, 8(1), 26. https://doi.org/10.1186/s13102-016-0052-y

Declaración de uso de inteligencia artificial

Herramientas utilizadas:

- DeepSeek se empleó exclusivamente como apoyo para mejorar la redacción de la documentación. Todas las sugerencias fueron revisadas, corregidas o descartadas por el alumno, quien mantuvo la responsabilidad final sobre el contenido, la estructura argumentativa y la versión final del texto.
- Claude se utilizó para asistir en la generación de código informático, siguiendo instrucciones explícitas proporcionadas por el alumno. Cada fragmento de código fue revisado, probado, corregido y validado por el alumno antes de su integración en el proyecto. Las decisiones de diseño, la interpretación de resultados y la depuración final permanecieron bajo control del alumno.

El uso de estas herramientas se realizó conforme a principios de transparencia y uso ético de IA. Ninguna salida fue incorporada sin verificación, y asumo la responsabilidad completa por la exactitud, originalidad y calidad del producto final.